

Previsão de Resultado de Partidas de League of Legends

Modelo de classificação para estimar a vitória do Blue Team a partir do estado da partida no early game.

9.879

partidas analisadas

40

colunas originais

ROC 0,806

desempenho final

1. Briefing do problema

Case 03 - Tech Lead da Riot Games: prever o vencedor usando dados após o início da partida.

Pergunta central

Com base no estado da partida nos primeiros minutos, é possível prever de forma confiável qual equipe vencerá?

Alvo: blueWins = 1 indica vitória do Blue Team.

Tipo de problema: classificação binária.

Resultado esperado: modelo + interpretação dos fatores do early game.

Entrega: notebook técnico e apresentação executiva em PDF.

Entrada


Ouro, XP, kills, farm, visão, dragões, arauto e torres no early game.

Saída

Probabilidade de vitória do Blue Team e explicação dos principais sinais preditivos.

2. Metodologia do projeto

Pipeline técnico usado para transformar dados brutos em decisão de modelo.



Princípio metodológico

O conjunto de teste ficou reservado para uma única avaliação final. A seleção de modelo e o tuning foram feitos exclusivamente com dados de treinamento e validação cruzada.

3. Base de dados e qualidade

Auditoria inicial antes de qualquer modelagem.

9.879

linhas / partidas

40

colunas originais

0


valores nulos

0

linhas duplicadas

30

features após seleção



Target praticamente balanceado

Derrotas Blue: 4.949 (50,1%).

Vitórias Blue: 4.930 (49,9%).

Não foi necessário balanceamento artificial.

Sem imputação: a base não contém valores faltantes.

4. Redundâncias tratadas antes da modelagem

Nem toda coluna deve entrar no modelo: algumas repetem a mesma informação.

Relações demonstradas na EDA

$\text{blueGoldDiff} = - \text{redGoldDiff}$

$\text{blueExperienceDiff} = - \text{redExperienceDiff}$

$\text{blueKills} = \text{redDeaths}$

$\text{blueDeaths} = \text{redKills}$

$\text{GoldPerMin} = \text{TotalGold} / 10$

$\text{CSPerMin} = \text{Minions} / 10$

Decisão de projeto

Remover apenas redundâncias exatas e identificador gameId.
Manter informações complementares dos dois times.
Evitar multicolinearidade e peso duplicado em modelos lineares.
Registrar a decisão para transparência e reprodutibilidade.

38

features antes

30


features usadas

5. Principal insight da EDA: vantagem de ouro

A relação entre ouro aos 10 minutos e vitória forma uma progressão clara.

Leitura executiva

A taxa de vitória sobe de 13,6% em grande desvantagem para 87,0% em grande vantagem de ouro.




Ouro é um proxy de kills, farm, objetivos e controle de mapa.

O gráfico mostra associação, não causalidade isolada.

Esse padrão orientou a interpretação do modelo final.

6. Eventos e objetivos do early game

First Blood, Dragão e Arauto aumentam a taxa observada de vitória Blue.



Destaques

First Blood: 39,7% -> 59,9%.

Dragão: 41,9% -> 64,1%.


Arauto: 47,7% -> 59,5%.

Testes qui-quadrado indicaram associação estatística com o resultado.

Interpretação: objetivos iniciais capturam vantagens estratégicas, mas o modelo mostra que economia e experiência ainda são os sinais mais fortes.

7. Comparação de modelos

Validação cruzada estratificada no treino; o teste final permaneceu fechado.



Resultado da comparação

A Regressão Logística liderou a validação cruzada, superando Random Forest, Decision Tree e SVM Linear.

Modelo simples, bom desempenho e alta interpretabilidade.

Random Forest ficou como segundo candidato.

Árvore isolada foi instável e menos robusta.

A escolha considerou ROC-AUC, F1, Log Loss e estabilidade.

8. Tuning e seleção final

Ajuste de hiperparâmetros sem consultar o conjunto de teste.

Hiperparâmetro escolhido

Regressão Logística com $C = 0,03$

ROC-AUC médio em CV: 0.8109



Por que este modelo?

Melhor equilíbrio entre desempenho e simplicidade.
Probabilidades úteis para análise de confiança.
Coeficientes permitem explicar fatores do early game.
Tuning produziu ganho pequeno: o modelo já era estável.

Decisão antes do teste: usar a Regressão Logística otimizada como modelo final.

9. Avaliação final em dados não vistos



Primeira e única abertura do conjunto de teste reservado.



Acurácia final: 71.66% | ROC-AUC: 0.8060 | Log Loss: 0.5313

10. Interpretação do modelo

O modelo aprendeu uma história consistente com a EDA.



Mensagem ao stakeholder

O modelo é mais assertivo quando o early game já mostra uma vantagem clara; em partidas equilibradas, a incerteza é maior e isso aparece nas probabilidades.

11. Conclusão

É possível prever o vencedor a partir do early game?

Sim - com desempenho consistente e interpretação útil para o stakeholder.

Modelo final

Regressão Logística otimizada, ROC-AUC 0,806 e acurácia 71,66% no teste.

Fatores-chave

Ouro, experiência e dragões aparecem como sinais preditivos centrais.

Uso prático

Priorizar leitura probabilística: alta confiança ajuda a identificar partidas com vantagem clara.

Limites

Resultado depende do dataset, patch/população e não inclui composição de campeões/jogadores.

Próximos passos no GitHub: publicar notebook executado, PDF, README, requirements e pasta data/ com instruções de reprodução.